

Screenshot-dan qayda və vizual sübuta

AI Gaming · Rule-Aware Visual Regression · Ali + Celal · NeuroBridge.SI

Hər fərq bug deyil.

İtən obyekt isə diqqət tələb edir.



QA-nın qərarı üçün

- 01 Nə dəyişib?
- 02 Hansı qayda tətbiq olunur?
- 03 Sübut haradadır?

İstifadəçi screenshot pair + allow/deny rules verir.

Prototype region crop, qərar səbəbi və paylaşılacaq evidence ZIP yaradır.

Model müşahidə edir. Kod qərar verir.

Frozen DINOv2 + pixel proposals → two-stage VLM → whole-scene audit → deterministic policy



Reliable forbidden evidence → FAIL

Uncertainty, error və incomplete coverage → REVIEW

Inference only: training / fine-tuning yoxdur. Labels inference input-a daxil edilmir.

PASS bütün mümkün bug-ların yoxluğuna zəmanət vermir.

Final source SHA 79a0ef7 · OpenRouter / google/gemini-3.5-flash · low · prompt v9

Real bug: barrel yox olub → FAIL

C2 saved result · vr_4b921c5d · reliable forbidden region R1 + scene audit · D1



Gemini / FAIL

Missing barrel · R1 / D1
Validated visual evidence

Qwen baseline / REVIEW

Eyni pair: “texture / lighting”
Region verdict uncertain

C2 run 20261009T123704Z-8e4e19 · config eaa371255716
4 fresh calls · orchestration wall 31.520 s · pipeline 30.2167 s

Bu kadr actual model-input crop-dur; UI screenshot deyil. Nəticə committed raw row-dan göstərilir.
Bir seçilmiş dev demo accuracy sübutu deyil; replay live inference kimi göstərilmir.
Mənbə: docs/c2_openrouter/C_predictions.jsonl @79a0ef7; a1_evidence/; C2_RECOMPUTED.json.

Qwen baseline / development diagnostic

12 pairs · 5 bug / 7 clean · Qwen 2.5-VL 3B · prompt v9

Arm	PASS / FAIL / REVIEW	Coverage	Bug false-PASS	Clean PASS
A / pixel	12 / 0 / 0	12/12	5/5	7/7
B / full-frame VLM	8 / 0 / 4	8/12	5/5	3/7
C / hybrid	0 / 0 / 12	0/12	0/5	0/7

Qwen C: 0/5 false-PASS, coverage 0/12 — bütün cütlər REVIEW.

C2 / OpenRouter Gemini — raw rows yoxlanıb · SHA 79a0ef7

B və C: 1 PASS / 4 FAIL / 7 REVIEW · coverage 5/12 (41.7%) · bug false-PASS 1/5
C: bug FAIL 3/5, clean false-FAIL 1/7; B: bug FAIL 2/5, clean false-FAIL 2/7. Clean PASS 0/7 hər ikisində.
Saylar eyni; iki pair-də qərarlar fərqlidir. DINOv2 üstünlüyü ayrıca sübut edilməyib.

A3 = A1: 36/36 qərar eyni, 80 fresh calls; determinism check, ikinci sample deyil.
Labels A1 başladıqdan sonra dondurulub; 4/5 bug label assistant təklifindən Ali təsdiqinə gəlib.
Dev12 held-out deyil. Mənbə: a1_evidence/predictions_A,B,C.jsonl; A3_review.md; C2_RECOMPUTED.json.

Əsas failure / missing pedestal

vr_c1f47c57 · D1 qalır · BEFORE stone pedestal → AFTER floating slab

BEFORE / reference



AFTER / candidate



C2 B və C: PASS — yanlış avtomatik təsdiq

Raw rows verified · run 20261009T124621Z-0b0c2b · config eaa371255716

C2 hər arm: bug false-PASS 1/5 · coverage 5/12 (41.7%). Bu PASS uğur nümunəsi deyil.

Yoxlanmış Qwen baseline: B PASS; C REVIEW. C: false-PASS 0/5, coverage 0/12.

Şəkil post-freeze audit-də yoxlanıb; frozen label mətni dəyişdirilməyib.

Labels A1 başlayandan sonra dondurulub; 4/5 bug label assistant təklifi + Ali təsdiqidir.

Mənbə: labels_audit.md; A3_review.md; C2_RECOMPUTED.json (source SHA 79a0ef7).

Qərardan paylaşılacaq evidence paketinə

Evidence JSON + Markdown report + input hashes + paired crops + exact runtime identity

REPORT ZIP

report.md
analysis.json
evidence.json
rules.yaml
images/
crops/
diagnostics/

Təkrarlana bilən evidence

Run ID + rule ID + model / prompt
Input və crop SHA-256
Assessed / NOT assessed scope

Explicit reference approval

İnsan təsdiqi + versioned history
FAIL / REVIEW override guard

194 tests passed / 6 skipped at source SHA 79a0ef7 · offline verification
3 local Qwen ZIP yoxlanıb; 12 C2 ZIP üçün Celalın verification records-u var.
C2 ZIP bytes transfer-i və final browser download check hələ gözlənilir.

Native cache field unknown (replay possible); C2 freshness ayrıca 80 call/stage record ilə yoxlanıb.
Bu səhifə evidence schema təqdimatıdır; final UI recording deyil.

Növbəti pilot: perception və yoxlama scope-u

İşləyən prototype + ölçülmüş development evidence + görünən failure

MODEL

Daha güclü VLM ilə
barrel və booth FAIL alıb.

Pedestal hələ yanlış PASS.
Clean PASS: 0/7.

EVIDENCE

B+C: 80 fresh calls
0 retries

Provider-reported total:
\$0.2871945
Eyni 12 pair, iki arm

NEXT

Fresh pre-labelled scenes
Ayrı label raters

DINO ablation
QA evidence-review vaxtı

QA üçün qayda, crop və traceable qərar.

Unknown halları human review-a verən screenshot comparison prototype.

Dev12 held-out deyil. Labels A1 başlayandan sonra dondurulub; 4/5 bug label assistant təklifi + Ali təsdiqidir.

Source / class imbalance var. DINOv2 advantage və QA workload reduction ölçülməyib.

Frozen runtime: google/gemini-3.5-flash / low / v9 / eaa371255716

VideoGameQA-Bench · CC BY 4.0 · revision 2afbdc... · Ali + Celal